Ensemble



2022.01.11
Dongmin Kim (tommy.dm.kim@kaist.ac.kr)


TODO

- 앙상블 (ensemble)
- Random Forest
- Gradient Boosting
- XGBoost, LightGBM
- 여러 모델의 앙상블
- Kaggle Titanic에 Random Forest, XGBoost, LightGBM 적용하기

I. Ensemble

앙상블 (Ensemble)

- 앙상블 (ensemble): 하나의 단일 모델로 예측 하기보다, 여러 모델의 output을 합치는 과정
- Classification
 - Hard voting: one-hot을 결합
 - Soft voting: probability를 결합
- Regression
 - Mean, Median
- 방법론
 - Bagging (random forest)
 - Boosting (boosting algorithms)
 - Stacking



2. Random Forest


Random Forest



x 10000 =




Random Forest




3. Gradient Boosting, Xgboost, LightGBM

Boosting



Gradient Boosting



Gradient Boosting

- Boosting은 앞선 모델의 약점을 보완해가는 과정
- Gradient Boosting은 앞선 모델의 약점을 Gradient를 통해 포착
 - MSE Loss

$$-\frac{\partial L}{\partial y_p} = 2(y_i - y_p)$$

Cross entropy Loss

$$rac{\partial C}{\partial z_i} = \sum_k rac{\partial C}{\partial s_k} rac{\partial s_k}{\partial z_i} = s_i - y_i$$

- Useful References
 - statquest: https://youtu.be/3CC4N4z3GJc

XGBoost, LightGBM


기존 Gradient Boosting 방법론을 발전시킨 알고리즘들

- XGBoost (eXtreme Gradient Boosting)
 - https://youtu.be/OtD8wVaFm6E
 - learning rate (eta): step size
 - gamma: tree의 minimum impurity decrease와 같은 역할. gamma가 커지면 조금 더 보수적으로 가지치기를 함 (regularization)
 - n_estimators: tree 개수

- LightGBM (Light Gradient Boosted Machine)
 - https://youtu.be/4C8SUZJPIMY
 - learning rate (eta): step size
 - lambda_l1, lambda_l2 : regularization
 - n_estimators: tree 개수

4. 여러 모델 앙상블하기

Voting



5. Kaggle

Kaggle Titanic에 Random Forest, XGBoost, LightGBM 적용하기

- 0. Kaggle 노트북 준비하고, decision tree 부분까지 실행시키기
- 6. Random Forest, XGBoost, LightGBM 모델 써보기
 - 6.1. 모델 트레이닝 시키기
 - 6.2. accuracy 출력, confusion matrix 그리기, classification report 생성해보기, feature importance 뽑아보기
- 7. Hyperparameter Tuning
 - 7.1. sklearn의 gridsearchCV를 사용하여, 튜닝을 해봅시다.
 - 7.2. 튜닝 된 모델들에 대하여, 6.1, 6.2 에서 했던 모든 과정들을 반복해주세요.
- 8. Voting
 - 8.1. sklearn의 soft voting, hard voting을 이용하여, decision tree, random forest, xgboost, lightgbm, logistic regression 총 5개의 모델을 앙상블 해주세요.

[Submission 3]

- 우리의 세번째 모델에 대한 결과를 제출해봅시다.
- 오늘 다룬 decision tree, random forest, boosting 모델들, 튜닝, 앙상블 등을 적절히 잘 활용해서, 가능한 최고의 결과를 뽑아보세요!