## **Review of ML Process & Classification**



2022.01.11
Dongmin Kim (tommy.dm.kim@kaist.ac.kr)

### TODO

- 머신러닝의 과정 리뷰
- 분류 (Classification) 리뷰
- Kaggle Titanic EDA

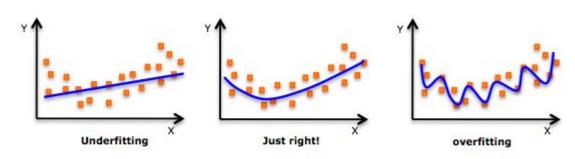
I. Machine Learning Process

## 머신러닝의 과정 리뷰

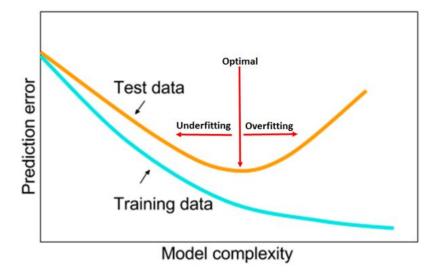


### 머신러닝의 과정 리뷰

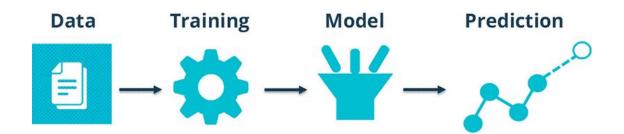




An example of overfitting, underfitting and a model that's "just right!"



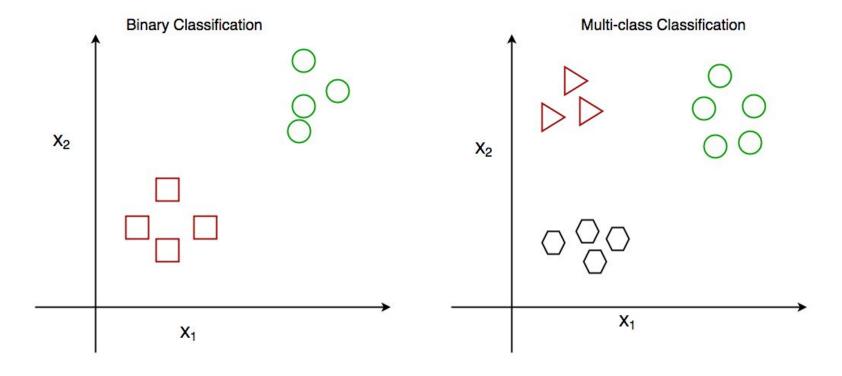
#### 머신러닝의 과정 리뷰



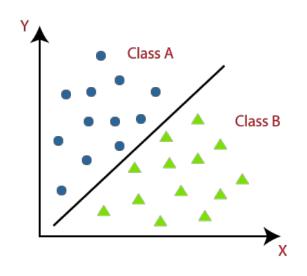
- Data
  - EDA (Exploratory Data Analysis)
  - 전처리 (Preprocessing)
- 학습 (Training)
  - 모델 선정
  - Loss Function + Regularization
  - hyperparameter tuning
- 평가 (Evaluation)
  - 정확도 (accuracy), MSE 등의 metric으로 test set에 대해 평가
  - 결과의 시각화

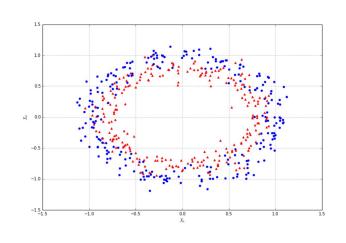
2. Classification

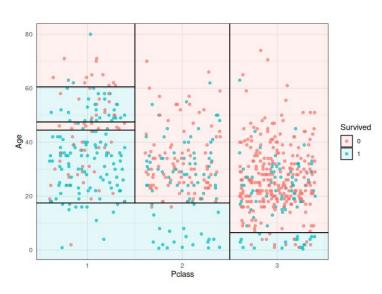
## Data



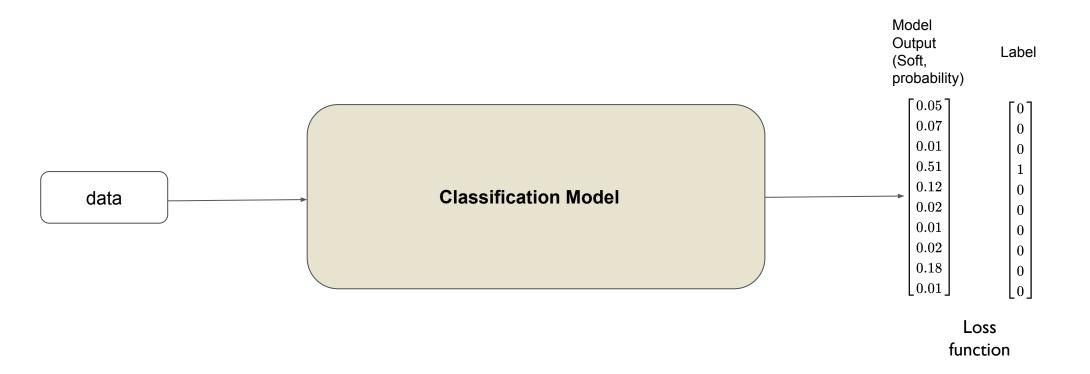
# Classification == 선긋기



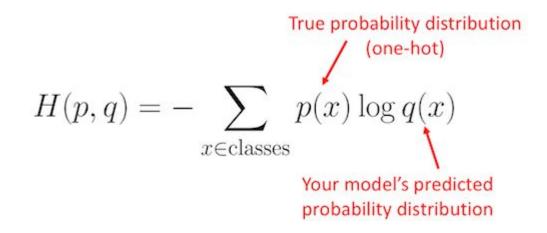




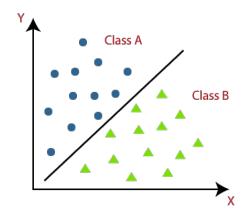
#### Classification의 입출력

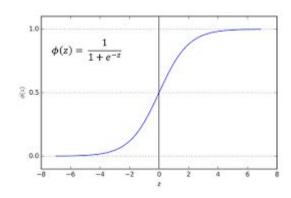


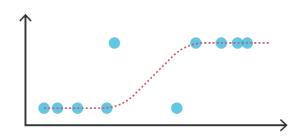
#### **Cross Entropy**



# Logistic Regression의 출력







## Metrics 1: Accuracy

Accuracy (정확도) = 맞은 개수 / 총 데이터 수

## Metrics 2: Precision, Recall and F1-score

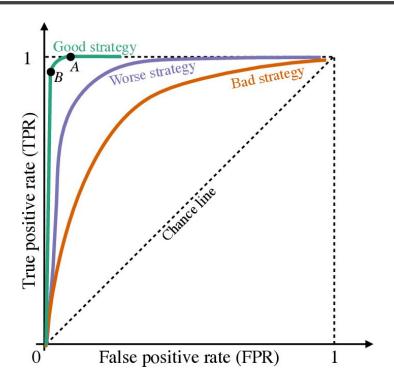
TP,TN, FP, FN

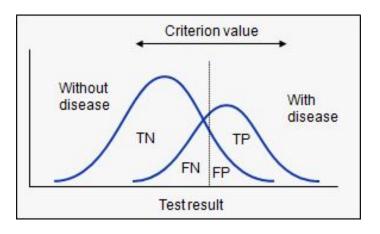
Precision, Recall, FI score

| True  | Positive |
|-------|----------|
| True  | Negative |
| False | Positive |
| False | Negative |

| Accuracy  |  |
|-----------|--|
| Precision |  |
| Recall    |  |
| F1 Score  |  |

### Metrics 3: ROC, AUC





#### Summary

- 머신러닝의 과정 (supervised setting) 리뷰
  - Model input / output
  - Cost function, Regularization
  - 데이터 전처리
  - Data split (Train / Validation / Test) and hyperparameter tuning
- 분류 (Classification) 과정 리뷰
  - Classification objective
  - Cost function of classification task
  - Accuracy and other metrics

3. Kaggle

#### Kaggle Titanic EDA

- 0. Kaggle 가입이 안되어 있다면, 가입하기
- 1. 일단 제출해보기 [Submission 1]
  - 1.1. Pandas를 활용하여 train.csv, test.csv, gender\_submission.csv 확인해보기
  - 1.2. Survived 값을 모두 1 혹은 모두 0으로 하여, 제출해보기
- 2. EDA
  - 2.1. train data의 "Survived" column의 분포 보기. 0 (dead), 1 (Survived) 의 개수 출력
  - 2.2. Pclass, 성별에 따른 생존자 분포를 확인해보세요 (hint: sns.barplot).
    다 하신 분들은, 추가적으로 다른 feature들도 살펴보고 plot 해보며 insight를 얻어 봅시다.
  - 2.3. 뭔가 쓰기 힘들 것 같은 feature가 있나요? Nan값이 있는지 살펴보고, 숫자로 처리하기 쉬울만한 데이터만 처리하려 합니다. 리스트 input\_features, output\_features를 선언하고, feature 이름들을 넣어주세요. 그리고 변수 X에 input, y에 output을 할당해주세요.
- 3. 데이터 가공하기
  - 3.1. 결측치를 처리합시다. na (혹은 null) 값을 모두 -1로 채워주세요.
  - 3.2. train.csv를 읽은 pandas dataframe을 train/test 80%, 20% 비율로 분리해주세요.